VITOR DOS SANTOS MARINHO

Engenheiro de Dados & IA · Databricks · PySpark · Delta Lake · Azure Synapse · Data Factory · RAG

Taquaritinga, SP (Remoto) · vitomarinho6@gmail.com · (16) 99738-4472 · LinkedIn · GitHub · Portfólio

RESUMO PROFISSIONAL

Engenheiro de Dados desde 2023, construindo **pipelines ETL/ELT e Data Lakes no Azure** (**Synapse Analytics, Data Lake Storage Gen2, Data Factory**) e **Lakehouses em Databricks** (PySpark, Delta Lake, Medallion), com governança sob **LGPD**. Na **CBMM**, tratei dados do **SAP** em Databricks com **Unity Catalog**, da camada raw até o consumo no Power BI. Conduzi a migração de um ambiente de dados para um **novo tenant Azure**, de Dev a Prod, com validação de paridade, e atuei na POC do **Microsoft Fabric** com a Microsoft, escrevendo a governança do ambiente. Atuei com dados da CBMM (mineração e metalurgia) e do A.C.Camargo Cancer Center (saúde). Nos projetos recentes levo essa base para a IA: pipelines que alimentam **RAG e agentes**, dado vetorial em **PostgreSQL/pgvector** e avaliação automatizada. Python e SQL no dia a dia.

COMPETÊNCIAS TÉCNICAS

- **Engenharia de Dados:** ETL/ELT · Databricks (Unity Catalog, Jobs, Lakehouse Federation) · Apache Spark · PySpark · Spark SQL · Delta Lake · dados SAP (Material Ledger, MM) · arquitetura Medallion (Bronze, Silver, Gold) · Azure Synapse Analytics (notebooks PySpark, SQL pools) · Azure Data Lake Storage Gen2 · Data Warehouse · Azure Data Factory · Microsoft Fabric · modelagem relacional e dimensional
- **Linguagens & Bancos:** Python (Pydantic, SQLAlchemy, pytest) · SQL avançado · Oracle · PostgreSQL · pgvector · Supabase
- **Cloud & DevOps:** Azure (Data Factory, Synapse, Storage, Key Vault, Monitor, Log Analytics, DevOps: Repos, Boards, CI/CD) · AWS · Docker · Git/GitHub · GitHub Actions
- **Governança & Qualidade:** qualidade e linhagem de dados · RBAC · LGPD · anonimização e mascaramento de PII · documentação técnica (ADRs)
- **IA aplicada a dados:** RAG (embeddings, busca híbrida, re-ranking) · LangChain · LangGraph · avaliação de LLM (evals) · guardrails
- **Visualização & Integração:** Power BI · APIs REST · FastAPI · n8n

EXPERIÊNCIA PROFISSIONAL

Engenheiro de Dados e IA · Autônomo (PJ) · Abr/2026 a Atual

Projetos de dados e IA sob demanda para pequenos negócios, em paralelo à busca por posição CLT ou PJ.

- Modelei e integrei dados em **PostgreSQL/Supabase** para sistemas multi-tenant de agendamento e cardápio digital em produção, com backend Python.
- Construí a camada de memória de curto e longo prazo em Postgres para agentes conversacionais, que consultam bases reais (histórico, regras de negócio, agenda) antes de responder.
- Integrei sistemas via API e automações em n8n, com revisão por pull request.

Engenheiro de Dados Júnior · UPBI Data & AI · Dez/2023 a Mar/2026 (PJ)

Efetivado como júnior após o programa de estágio em dados da UPBI (Ago/2023 a Nov/2023).

CBMM (mineração e metalurgia) · Nov/2025 a Mar/2026

- Tratei dados do **SAP** (Material Ledger e MM) em **Databricks com Unity Catalog, PySpark e Delta Lake**, da camada raw até as views dos relatórios Power BI de custo de produção, suprimentos e comercial; ajustei e mantive os jobs de orquestração (Databricks Jobs com cargas paralelas e sincronização antes da fato).
- Implementei o padrão de higiene de dados do cliente em **funções PySpark reutilizáveis** (padronização por tipo, metadados de carga, chave hash MD5, soft delete), modelei dimensões na camada de serviço e validei a linhagem dos objetos usados pelos relatórios via information_schema.
- Conduzi minhas entregas em sprints no **Azure DevOps (Boards)**: user stories com DoR e DoD, tasks com as atividades executadas e as horas de cada uma, e levantamento semanal de horas para o relatório enviado à gestão de dados do cliente.

A.C.Camargo Cancer Center (saúde, oncologia) · Dez/2023 a Out/2025

- Construí e sustentei pipelines **ETL/ELT no Azure Synapse Analytics**, com **notebooks PySpark** e **SQL pools**, consumindo origens **Oracle** e o **Data Warehouse** do cliente, com dados no **Azure Data Lake Storage Gen2**, ingestão via **Azure Data Factory** e **Logic Apps** (anexos de e-mail) e monitoramento em Azure Monitor e Log Analytics.
- **Conduzi a migração de um ambiente de dados para um novo tenant Azure** (Synapse, pipelines, Storage, Key Vault, CI/CD): mapeamento completo, migração gradual de Dev, Prod tabela a tabela e validação de paridade de linhas, tamanhos e tipos de arquivo.
- Atuei na **POC do Microsoft Fabric** com a Microsoft e o time de Arquitetura: configuração inicial, workspace do projeto, documentação de governança (nomenclatura, padrões de tabelas, acessos por nível) e habilitação de engenheiros pleno e sênior.
- Administrei o **Azure DevOps** do projeto: aprovação de branches, RBAC por função e acompanhamento diário de atividades no Boards para o gerente de dados do cliente.
- Apliquei governança, RBAC e LGPD, com **anonimização de dados sensíveis de saúde**, e otimizei transformações PySpark e consultas SQL de grande volume para o Power BI.

PROJETOS

Lakehouse SAP em Databricks: custo de produção e suprimentos · projeto profissional, UPBI para a CBMM
Dados do SAP Material Ledger e MM, orçamento via catálogo federado em SQL Server e preços de mercado (Platts, CRU) em quatro camadas: raw como cópia fiel, harmonizada com higiene e chave MD5, serviço com dimensões e fatos, views para o Power BI. Decisão do modelo: nenhum tratamento na raw, para reprocessar qualquer regra sem voltar ao SAP.

Data Lake em Azure Synapse (oncologia) · projeto profissional, UPBI para o A.C.Camargo Cancer Center
Data Lake no Azure: ingestão via Logic Apps e Data Factory, dados no Data Lake Storage Gen2 e processamento no Azure Synapse Analytics, com regras de qualidade e validação, linhagem e anonimização de dados sensíveis sob LGPD.

ARIA Health, pipeline Medallion + agente de IA · github.com/VitorSMarinho/agient-aria-health · Demo
Pipeline em Databricks (Bronze, Silver, Gold) sobre **dados clínicos fictícios em CSV**, com carga no Supabase. Em cima dele, agente com tool calling servido por FastAPI e front em Next.js. RAG com embeddings locais e pgvector, suíte de evals e observabilidade de tokens, latência e custo. Em produção o RAG está desligado por limite de memória do plano gratuito; roda de ponta a ponta localmente.

payments-data-harness · github.com/VitorSMarinho/payments-data-harness · em desenvolvimento
Harness para produtos de dados de pagamentos com dados públicos do Banco Central e dados sintéticos. Arquitetura, contratos entre etapas e princípios (qualidade como portão, guardrails de PII/PCI, aprovação humana antes da camada gold) definidos e documentados no README. Estrutura do repositório criada; CI de qualidade (ruff, mypy, pytest) em andamento; ingestão, camadas e agentes planejados.

Agente Analista Financeiro · projeto de portfólio, código sob pedido
Dado ao vivo da API do Banco Central combinado com busca híbrida (filtro relacional + vetorial com índice HNSW) em PostgreSQL/pgvector, orquestrado em LangGraph, com citação obrigatória de fonte e guardrail que recusa recomendação de investimento.

FORMAÇÃO

Tecnólogo em Sistemas para Internet · FATEC Taquaritinga · Concluído em Jun/2026

IDIOMAS

Português (nativo) · Inglês técnico (leitura)